

Capstone Módulo 02 — Sistema de Prompt Engineering para Aplicações Empresariais

Intelligent Incident Triage & Response System (Sistema Inteligente de Triagem e Resposta a Incidentes) — documento principal: relatório final de avaliação.

Nota. Este PDF é o documento principal do trabalho. O projeto completo (8 prompts V1/V2, schemas, suíte de 12 casos, scripts, saídas brutas das execuções, exemplos e demais documentos) é entregue separadamente em arquivo .zip; os caminhos citados (docs/..., prompts/..., tests/..., results/...) referem-se a esse projeto. Nomes de arquivos, códigos de teste (TC-xxx) e valores de campos (CORRIGIR, SUCCESS, etc.) foram mantidos como no projeto.

Relatório Final de Avaliação

Resumo Executivo

Foi projetado, testado e melhorado um pipeline de quatro prompts para **triagem e resposta inteligente a incidentes**. A V1 (linha de base) e a V2 (melhorada) foram executadas nos mesmos 12 casos de teste, em 3 rodadas (**72 execuções completas do pipeline**), além de um teste do validador com defeito único (**60 execuções apenas do Prompt 04**; 78 execuções de um desenho anterior, contaminado e com múltiplos defeitos, foram mantidas como legado) e uma passada de juiz independente para afirmações não sustentadas. Os resultados são reais, produzidos por sub-agentes LLM e pontuados por `tests/evaluate.py`; temperatura e demais parâmetros de amostragem *não eram configuráveis no ambiente utilizado*.

- Sucesso nas tarefas **86,1% → 94,4%** (31/36 → 34/36, +8,3 pp); Nota Geral de Qualidade **90,9% → 97,6%** (+6,7 pp).
- As maiores diferenças estão em consistência e especificação (consistência 80,6% → 91,7%, coerência de status 58,3% → 100%, estabilidade do `incident_id` 0/12 → 12/12, validade sob enums estritos das saídas do validador 87,2% → 100%), acurácia de fallback 91,7% → 100% e detecção direcionada do validador em fixtures de defeito único 76,2% → 100% (16/21 → 21/21).
- **Não melhorou / piorou:** acurácia de categoria 100% → 97,2% (−2,8 pp; regressão no TC-007), consistência de categoria 97,2% → 94,4%; conformidade de schema e tratamento de ambiguidade já estavam em 100%; uma afirmação não sustentada ainda chegou à saída da V2.
- **A confiança no resultado é limitada:** a diferença de sucesso nas tarefas é de 3 execuções e os intervalos de 95% se sobrepõem (71,3–93,9% contra 81,9–98,5%). A linha de base já era forte (efeito teto) e a suíte é pequena.

Problema

A triagem de relatos de incidentes não estruturados deve ser padronizada, apoiada em evidências e nunca fabricar fatos ou causas; deve passar o caso a humanos quando a informação é insuficiente. Ver `docs/01_business_problem_and_scope.md` (não existia problema pré-definido para este capstone na

pasta do módulo, então foi usado o cenário alternativo do enunciado).

Arquitetura

P1 Análise e Normalização da Entrada → P2 Classificação e Análise de Contexto → P3 Decisão e Recomendação → P4 Validação e Resposta Final, com um orquestrador que fornece metadados confiáveis, encaminha entrada bloqueada direto ao estágio 4 e repete o estágio 3 uma vez quando o veredito é CORRIGIR. Quatro JSON Schemas definem os contratos (congelados entre as versões). Diagrama e tabelas de contrato: docs/02_architecture_and_orchestration.md. A fonte externa é **simulada** (observações embutidas na entrada de teste); o orquestrador foi executado pelo agente de teste, não por código.

Sistema de Prompts

Cada prompt tem seções de papel/responsabilidade, entrada/contexto, instruções/restrições e contrato de saída; a V2 acrescenta hierarquia de instruções, um exemplo trabalhado e regras derivadas das evidências. Técnicas (prompting estruturado, encadeamento, raciocínio estruturado por campos auditáveis, protocolo de campos inspirado em ReAct, few-shot, prompting por restrições, validador de autoverificação, imposição de schema), onde e por quê: docs/03_prompt_design_rationale.md. Arquivos: prompts/0X_*/v1.md e v2.md (8 prompts).

Metodologia de Teste

Rubrica fixada antes de qualquer saída ser inspecionada; 3 rodadas independentes por versão; executores cegos (proibidos de ler o comportamento esperado); juiz independente para afirmações não sustentadas; fixtures de defeito único para o validador (7 falhas + 3 controles limpos, válidos nos dois contratos), porque as execuções naturais tiveram poucos erros a montante para medir o validador. Registro de reprodutibilidade, ressalvas de execução e ameaças à validade: docs/05_evaluation_methodology.md. Duas correções de rubrica/fixtures feitas após a V1 (aplicadas às duas versões) estão registradas em tests/evaluation_rubric.md §6. Ressalvas principais: dentro de uma rodada os casos foram produzidos em um único contexto de agente; executor e juiz são da mesma família de modelos.

Cobertura de Testes

12 casos: simples (TC-001, 002), complexos (003, 004), ambíguos (005, 006), incompleto (007), contraditório (008), dependente de fonte externa (009), falha de fonte externa (010), adversarial/prompt injection (011), fallback obrigatório (012; também 005, 007, 010). Comportamento esperado por caso: tests/expected_behaviors.md; versão legível por máquina: tests/test_cases.yaml.

Métricas

Dez métricas obrigatórias mais três diagnósticos, definidas em tests/evaluation_rubric.md. Nota Geral = $0,20 \cdot \text{Sucesso} + 0,15 \cdot \text{Classificação} + 0,10 \cdot \text{Schema} + 0,10 \cdot (1 - \text{Alucinação}) + 0,10 \cdot \text{Fallback} + 0,10 \cdot \text{Ambiguidade} + 0,10 \cdot \text{Consistência} + 0,075 \cdot \text{Detecção} + 0,075 \cdot \text{Ancoragem}$ (pesos somam 1,0).

Resultados da V1

Taxa de sucesso nas tarefas

V1: 86,1% (31/36)

Conformidade de schema

V1: 100% (144/144 saídas de estágio)

Acurácia de classificação

V1: 100% (categoria 36/36, severidade 36/36)

Taxa de alucinação / afirmações não sustentadas

V1: 5,6% (2/36)

Acurácia de fallback

V1: 91,7% (22/24) — 0 ausentes, 2 excessivos

Tratamento de ambiguidade

V1: 100% (9/9)

Consistência entre rodadas

V1: 80,6%

Taxa de detecção do validador (defeito único, detecção direcionada)

V1: 76,2% (16/21); falsos positivos 0% (0/9)

Validade sob enums estritos das saídas do validador

V1: 87,2% (34/39)

Ancoragem em evidência externa

V1: 83,3% (5/6)

Nota Geral de Qualidade

V1: 90,9%

Diagnósticos

V1: coerência de status 58,3%; consistência do incident-id 0%

Padrões de Erro

Tabela completa com frequências, causas e correções: `results/error_patterns.md`. Principais padrões da V1: E09 saída inconsistente (instabilidade do ID em 12/12 casos; semântica sobrecarregada de `escalation_required` → 15/36 execuções incoerentes; variação de veredito/status entre rodadas), E02

afirmações causais não sustentadas (2/36), E06 escalonamento excessivo no caso de injeção (2/24), E10 pontos cegos do validador (0/2 vazamentos naturais detectados; VF-05 não detectado 3/3; 5/39 rótulos em texto livre). E01, E05, E07 e E08 foram observados 0 vezes.

Melhorias Implementadas

Dez mudanças C1–C10, cada uma com problema → evidência → hipótese → mudança → resultado, em `CHANGELOG.md`. Essência: `incident_id` fornecido pelo orquestrador; `escalation_required` ↔ `HUMAN_REVIEW_REQUIRED`, tabela determinística de status e mapeamento de status; rubrica de severidade e faixas de confiança; campos de evidência externa no estilo ReAct; mitigação condicional; validador recebendo o relato bruto com checklist C1–C8; roteador e laço de uma repetição; um exemplo few-shot por prompt.

Resultados da V2

Taxa de sucesso nas tarefas

V2: 94,4% (34/36)

Conformidade de schema

V2: 100% (138/138 saídas de estágio; 6 puladas pelo roteador)

Acurácia de classificação

V2: 98,6% (categoria 35/36, severidade 36/36)

Taxa de alucinação / afirmações não sustentadas

V2: 2,8% (1/36)

Acurácia de fallback

V2: 100% (24/24)

Tratamento de ambiguidade

V2: 100% (9/9)

Consistência entre rodadas

V2: 91,7%

Taxa de detecção do validador (defeito único, detecção direcionada)

V2: 100% (21/21); falsos positivos 0% (0/9)

Validade sob enums estritos das saídas do validador

V2: 100% (39/39)

Ancoragem em evidência externa

V2: 100% (6/6)

Nota Geral de Qualidade**V2:** 97,6%**Diagnósticos****V2:** coerência de status 100%; consistência do incident-id 100%; taxa de repetição 0%**Comparação V1 × V2****Sucesso nas tarefas****V1:** 86,1%**V2:** 94,4%**Δ pp:** +8,3**Δ rel:** +9,7%**Conformidade de schema****V1:** 100,0%**V2:** 100,0%**Δ pp:** 0,0**Δ rel:** 0,0%**Acurácia de classificação****V1:** 100,0%**V2:** 98,6%**Δ pp:** −1,4**Δ rel:** −1,4%**Taxa de alucinação (↓)****V1:** 5,6%**V2:** 2,8%**Δ pp:** −2,8**Δ rel:** −50,0%**Acurácia de fallback****V1:** 91,7%**V2:** 100,0%**Δ pp:** +8,3**Δ rel:** +9,1%

Tratamento de ambiguidade**V1:** 100,0%**V2:** 100,0%**Δ pp:** 0,0**Δ rel:** 0,0%**Consistência****V1:** 80,6%**V2:** 91,7%**Δ pp:** +11,1**Δ rel:** +13,8%**Detecção do validador (defeito único, direcionada)****V1:** 76,2%**V2:** 100,0%**Δ pp:** +23,8**Δ rel:** +31,3%**Validade sob enums estritos, saídas do validador****V1:** 87,2%**V2:** 100,0%**Δ pp:** +12,8**Δ rel:** +14,7%**Ancoragem****V1:** 83,3%**V2:** 100,0%**Δ pp:** +16,7**Δ rel:** +20,0%**Nota Geral de Qualidade****V1:** 90,9%**V2:** 97,6%**Δ pp:** +6,7**Δ rel:** +7,4%

Tabelas por caso, por fixture e de sensibilidade aos pesos: `tests/comparison.md`.

Melhoria Medida

Sucesso nas tarefas: (31/36 → 34/36)	V1 = 86,1%	V2 = 94,4%	Melhoria = +8,3 pontos percentuais
Consistência:	V1 = 80,6%	V2 = 91,7%	Melhoria = +11,1 pontos percentuais
Coerência de status: (diagnóstico)	V1 = 58,3%	V2 = 100%	Melhoria = +41,7 pontos percentuais
Deteccção do validador: (16/21 → 21/21; 7 fixtures de defeito único × 3 rodadas)	V1 = 76,2%	V2 = 100%	Melhoria = +23,8 pontos percentuais
Nota geral:	V1 = 90,9%	V2 = 97,6%	Melhoria = +6,7 pontos percentuais
Acurácia de categoria: (regressão, TC-007 r3)	V1 = 100%	V2 = 97,2%	Variação = -2,8 pontos percentuais

Por caso: TC-011 1/3 → 3/3, TC-004 2/3 → 3/3, TC-009 2/3 → 3/3, TC-007 3/3 → 2/3 (regressão), demais inalterados. A diferença da Nota Geral permanece entre +4,3 e +7,7 pp sob quatro esquemas de pesos diferentes. **Ressalva estatística:** os intervalos do sucesso nas tarefas se sobrepõem; trate como evidência direcional. Os ganhos mais fortes e menos sensíveis a ruído são os determinísticos (estabilidade do ID, coerência de estado); os que um revisor deve confiar menos são a taxa de alucinação (1 contra 2 eventos) e os números de deteção do validador (7 fixtures × 3 rodadas, padrões de evidência frouxos, validador simulado por LLM, casos de uma rodada produzidos em um único contexto).

Verificações pontuais feitas (não é anotação humana): os motivos dos bloqueios do validador V2 em VF-01, VF-02, VF-05 e VF-08 (rodada 1) foram lidos e correspondem à falha injetada; os registros marcados pelo juiz (V1: TC-003 r2, TC-009 r2; V2: TC-003 r2) e a saída do TC-007 r3 foram lidos e são coerentes com os rótulos.

Correções pós-revisão

Duas revisões adversariais independentes (Codex) questionaram os resultados. Cada afirmação foi conferida contra os dados (`results/raw/` , `tests/`) antes de agir.

Rodada 1

O ganho de deteção vinha só do VF-05, uma regra que só a V2 define Verificada?: Sim Ação tomada: Bundles de múltiplos defeitos rebaixados a legado; ver rodada 2
Registros ausentes do juiz contavam silenciosamente como "sem alucinação" Verificada?: Defeito de código confirmado; sem efeito nos números publicados Ação tomada: Carga do juiz tornada estrita (versão completa na rodada 2)
Qualquer valor diferente de APROVAR contava como deteção Verificada?: Confirmado no código; nenhum veredito inválido ocorreu Ação tomada: Um bloqueio exige saída válida no schema e veredito de bloqueio reconhecido

final_category/final_severity aceitam qualquer string

Verificada?: Confirmado

Ação tomada: schemas/final_output.strict.schema.json; validade estrita: saídas finais do pipeline 36/36 nas duas versões, saídas do validador 34/39 (V1) contra 39/39 (V2). Schema original inalterado

[EXTERNAL] confia em afirmações dentro do relato não confiável

Verificada?: Confirmado por desenho

Ação tomada: Documentado como limitação de segurança; não corrigido, não testado

O resumo final é escrito depois da auditoria C2 e não é auditado

Verificada?: Confirmado (TC-003 r2, V2)

Ação tomada: Documentado; correção da V3 listada

Rodada 2

A checagem "estrita" do juiz ainda aceita null / campos externos ausentes

Verificada?: Sim — só a presença das chaves era verificada

Ação tomada: Registros precisam ter listas de strings em *_unsupported e booleanos nos campos do TC-009/TC-010; tests/test_evaluate_guards.py comprova que registros nulos, ausentes, com tipo errado, duplicados ou faltando interrompem a pontuação. Os arquivos do juiz já publicados cumpriam a regra, então nenhum número mudou

Excluir o VF-05 não remove a contaminação dos outros bundles

Verificada?: Sim — VF-01 e VF-02 têm escalation_required=true com SUCCESS, VF-08 tem true com NEEDS_INFORMATION, e o VC-01 sem modificação é bloqueado pela V2 sem defeito injetado

Ação tomada: Substituídos por **fixtures de defeito único** válidos nos dois contratos (7 falhas, 3 controles limpos), executados para V1 e V2 x 3 rodadas (60 execuções reais do validador), exigindo que as notas cite a falha injetada. Resultado: V1 16/21 (76,2%), V2 21/21; 0/9 falsos positivos nas duas. Erros da V1: evidência externa inventada (aprovada 2/3) e contradição removida (aprovada 3/3). Nota geral recalculada: V1 90,9%, V2 97,6%

As conclusões atribuem confiabilidade ao pipeline sem execução isolada nem avaliação reservada

Verificada?: Sim (já declarado como limitação)

Ação tomada: Conclusões reescritas para descrever diferenças nos artefatos desta simulação conjunta; sem afirmações causais por componente

Ainda não feito (exige novas execuções ou trabalho humano): reexecutar cada estágio em contexto separado apenas com entradas contratuais, suíte reservada (held-out), revisão humana cega dos rótulos que decidem sucesso e alucinação e testes de fonte forjada ([EXTERNAL]). A checagem de padrão de evidência para a "detecção direcionada" é frouxa por desenho; li as notas de vários fixtures (V2 SF-02/SF-04/SF-06, V1 SF-02/SF-06) e correspondiam às falhas injetadas.

Limitações Restantes

1. **Suíte pequena e relativamente fácil.** 12 casos e 3 rodadas; a V1 forte deixa pouca margem; casos limítrofes aceitam vários rótulos, então as métricas de acurácia discriminam pouco.
2. **Fidelidade da execução.** Sub-agentes LLM simulam os estágios; casos de uma rodada compartilham contexto; sem parâmetros de amostragem; executor e juiz são da mesma família de modelos; sem rótulos humanos de referência.
3. **Fonte externa e orquestrador simulados.** Sem laço real de ferramenta; a validação de schema com repetição e o laço de repetição nunca foram acionados em execuções naturais (taxa de repetição 0%). Formato de entrada inválido, informação irrelevante e saída de estágio que não é JSON são *apenas desenho*.
4. **Os diagnósticos codificam a semântica da V2** (coerência), e a rubrica de severidade da V2 foi escrita junto com os rótulos esperados.
5. **Defeitos da V2 deixados sem correção para manter a comparação válida:** categoria em relatos vagos, limite da confiança, redação do SEV1 para janelas de acesso já encerradas, redação causal do resumo, regra de rótulo para `SKIPPED_BY_ROUTER` (`CHANGELOG.md`, "V2 residual gaps"). Enums de schema para os campos `final_*` não adicionados ao schema original.
6. **O validador em execuções naturais não está provado confiável:** aprovou uma categoria errada e seu próprio resumo trouxe uma afirmação causal não sustentada; sua vantagem medida em fixtures de defeito único (V1 76,2% contra V2 100%) é evidência de amostra pequena.
7. **Confiança em fonte externa.** Fatos `[EXTERNAL]` vêm do próprio relato não confiável; um remetente pode fabricar uma fonte "consultada". Não testado (sem casos de falsificação).
8. **A evidência sobre o validador é fina:** 7 fixtures de defeito único × 3 rodadas, padrões de evidência frouxos, fixtures escritos pelos mesmos autores e da mesma família de modelo do validador, e os 10 itens de cada rodada foram produzidos em um único contexto.
9. **Sem medição de custo, latência ou tokens.**

Considerações para Produção

Não está pronto para produção: sem código de orquestração, logs, redação de dados sensíveis, monitoramento ou fluxo de revisão humana; resistência a injeção medida em um caso e um fixture; parâmetros de amostragem não fixados. Passos necessários e análise de lacunas em `docs/07_production_considerations.md` (piloto em modo sombra, camada de redação, suíte rotulada maior, portão de promoção sobre estas métricas, modelo e parâmetros fixados).

Conclusão

Dentro desta simulação, os artefatos da V2 são mais consistentes e mais explicitamente especificados que os da V1: identificadores estáveis, campos de status coerentes, consistência de veredito de 100%, sem placeholders improvisados em rótulos, fallback correto em todas as 24 execuções avaliáveis e um validador que bloqueou e citou corretamente a falha em todas as 21 execuções de defeito único (V1: 16/21), sem falsos positivos. Também introduziu uma pequena regressão de classificação (TC-007) e ainda deixou passar uma afirmação não sustentada. Essas são diferenças entre as saídas de uma simulação conjunta por LLM, executada uma vez por rodada em contextos compartilhados, ajustada sobre os mesmos 12 casos e julgada por um LLM da mesma família; elas **não** mostram que cada mudança de prompt causou as diferenças, nem que o pipeline se comportaria assim com estágios isolados, suíte reservada ou resultados rotulados por humanos. O valor de engenharia do exercício está

tanto no *método* — linha de base congelada, execuções cegas, injeção de falhas, correções registradas e duas revisões que cada uma derrubou parte de uma conclusão anterior — quanto nos números. A próxima iteração deve corrigir as lacunas documentadas da V2, adicionar enums ao schema, rodar os estágios isolados numa suíte reservada e rotulada por humanos, incluir testes de fonte forjada e construir um orquestrador real com laço de ferramenta externa ao vivo.

Referências

- Wei, J., Wang, X., Schuurmans, D., Bosma, M., Ichter, B., Xia, F., Chi, E., Le, Q., & Zhou, D. (2022). *Chain-of-Thought Prompting Elicits Reasoning in Large Language Models*. arXiv:2201.11903. <https://arxiv.org/abs/2201.11903>
- Yao, S., Zhao, J., Yu, D., Du, N., Shafran, I., Narasimhan, K., & Cao, Y. (2022). *ReAct: Synergizing Reasoning and Acting in Language Models*. arXiv:2210.03629. <https://arxiv.org/abs/2210.03629>
- DAIR.AI. *Prompt Engineering Guide*. <https://www.promptingguide.ai/> (acessado em 2026-09-19).
- OpenAI. *OpenAI Platform Documentation*. <https://platform.openai.com/docs> (referência fornecida pelo curso; não consultada neste trabalho).